

آزمونک


دستیار هوشمند آزمون تطبیقی با **تشخیص**
بدفهمی‌های مفهومی برای آمادگی کنکور سراسری

این سند مشخصات کامل مهندسی پروژه «آزمونک» را برای تیم توسعه ارائه می‌کند: صورت مسئله و انگیزه، تحلیل رقبا، معماری نرم‌افزار، ریاضیات الگوریتم‌های تطبیقی، روش‌شناسی تشخیص بدفهمی، طراحی آزمایش علمی با گروه کنترل، نقشه راه اجرایی و آمادگی دفاع در برابر داوران.

پدیدآور: پویا

مدرسه:

دبیر راهنما:



فهرست مطالب

چهارده بخش و دو پیوست – از صورت مسئله تا آمادگی دفاع

۱ خلاصه اجرایی

تعریف محصول، مسئله و ستون‌های نوآوری

۲ صورت مسئله و انگیزه

گلوگاه‌های آزمون‌های ثابت و سؤال پژوهشی

۳ اهداف و معیارهای موفقیت

شاخص‌های کمی و قابل اندازه‌گیری

۴ تحلیل رقابت‌پذیری

ماز، قلمچی، گاج، کاگل – و جایگاه ما

۵ تعریف محصول و قابلیت‌ها

دامنه MVP، سناریوی کاربر و خارج از دامنه

۶ نوآوری‌های شش‌گانه

ستون‌های فنی تمایز پروژه

۷ معماری فنی

استک، لایه‌ها، مدل داده و API

۸ الگوریتم‌های هسته

Elo، سیاست انتخاب سؤال، SM-2، پیش‌بینی

۹ بانک سؤال و مدل داده

تاکسونومی بدفهمی و کنترل کیفیت

۱۰ طراحی آزمایش علمی

گروه کنترل، سنج‌ها و پروتکل چهار هفته‌ای

۱۱ نقشه راه اجرایی

پنج فاز هفته‌بندی‌شده تا داوری

۱۲ ریسک‌ها و ملاحظات

شناسایی، ارزیابی و راهکار کاهش

۱۳ آمادگی دفاع

ده پرسش احتمالی داوران و پاسخ‌ها

۱۴ پیوست‌ها

نمونه سؤال تشخیصی و پارامترهای الگوریتم

۱. خلاصه اجرایی

«آزمونک» یک وب اپلیکیشن آموزشی متن باز است که به جای برگه آزمون یکسان برای همه، برای هر دانش آموز یک مسیر تمرین شخصی می سازد؛ سطح توان او را با الگوریتم Elo تخمین می زند، سؤال بعدی را همیشه نزدیک به لبه توانش انتخاب می کند، و مهم تر از آن، از دل گزینه های غلط می فهمد دانش آموز **کجای مفهوم** را اشتباه فهمیده است.

مسئله ای که حل می کنیم از داخل کلاس درس آمده است، نه از یک فرصت بازار: آزمون های موجود، هم خوان با سطح هیچ دانش آموزی نیستند؛ گزارش آن ها فقط می گوید «چند درصد غلط زدی»، نه «چرا غلط زدی»، و هیچ کدام نتیجه ی اثرگذاری روش خود را با یک آزمایش علمی نشان نمی دهند. آزمونک این سه حلقه گمشده را با هم ترکیب می کند و محصول نهایی را در برابر داوران با عدد و نمودار دفاع می کند، نه با ادعا.

ستون های فنی پروژه سه چیز هستند: نخست، یک **موتور آزمون تطبیقی شفاف** بر پایه الگوریتم Elo که هر جزء آن را می توان در یک دقیقه برای داور توضیح داد؛ دوم، **گراف بدفهمی** – گزینه های فریبنده هر سؤال عمداً به یک بدفهمی مفهومی مشخص گره خورده اند و انتخاب آن ها توسط دانش آموز، سیگنال تشخیصی است؛ سوم، **آزمایش علمی با گروه کنترل** که اثر یادگیری را با پیش آزمون و پس آزمون روی چهل هم کلاسی اندازه می گیرد و نتیجه را به صورت اندازه اثر گزارش می کند.

دامنه نخست پروژه، فصل «مشتق و کاربردهای آن» از حسابان یازدهم است؛ فصلی که پر از بدفهمی کلاسیک و مستند است و خود پدیدآور کاربر واقعی آن است. نسخه کامل شامل مرور فاصله دار SM-2، داشبورد تحلیلی و پیش بینی نمره است و کد آن به صورت متن باز منتشر می شود تا شفافیت علمی و قابلیت تکرارپذیری تضمین شود.

۱۴

هفته تا بسته نهایی

۴۰

آزمودنی در آزمایش علمی

۱۵۰

سؤال هدف در MVP

۶

نوآوری فنی مستند

۲. صورت مسئله و انگیزه

هر دانش‌آموز کنکوری این تجربه را می‌شناسد: آزمون جامع می‌گیری، کارنامه می‌آید، و در کادر «تحلیل» فقط یک درصد نوشته شده است. اینکه در سؤال سوم چرا گزینه دو را انتخاب کردی، اینکه اشتباهت از عجله بود یا از فهم غلط مفهوم مشتق، و اینکه فردا باید چه چیزی را بخوانی – هیچ‌کدام در کارنامه نیست. ابزارهای فعلی «میزان» ضعف را می‌گویند، اما «ماهیت» ضعف را نمی‌گویند؛ و همین گم‌شده‌ترین حلقه یادگیری است.

۲.۱ – چهار گلوگاه آزمون‌های موجود

- **آزمون یکسان برای همه:** دانش‌آموز ضعیف دلسرد می‌شود چون سؤال‌ها سنگین است و دانش‌آموز قوی حوصله‌اش سر می‌رود چون سؤال‌ها تکراری و آسان است؛ هیچ برگه‌ای با «لبه توان» هیچ کسی هم‌خوان نیست.
- **بازخورد سطحی:** گزارش‌ها به سطح مبحث خلاصه می‌شوند («در مشتق ۴۰٪»); در حالی که دو غلط از دو دلیل کاملاً متفاوت می‌آیند – یکی مفهوم را نمی‌داند و دیگری علامت منفی را جا می‌اندازد – و درمان این دو یکی نیست.
- **نادیده گرفتن فراموشی:** بعد از آزمون، هیچ مکانیزمی سؤال یا مفهوم را در زمان بهینه به یادآوری برنمی‌گرداند؛ در حالی که منحنی فراموشی ابکینگهازمی‌گوید بهترین زمان مرور دقیقاً قبل از سقوط یادگیری است.
- **ادعای بدون مدرک:** هیچ‌کدام از پلتفرم‌های تجاری نتیجه اثر روش خود را با آزمایش کنترل‌شده منتشر نمی‌کنند؛ «هوشمند بودن» یک شعار بازاریابی است نه یک گزاره آزمون‌پذیر.

۲.۲ – چرا الان؟

سه اتفاق هم‌زمان، این پروژه را امروز برای یک دانش‌آموز ممکن کرده است: اول، بلوغ کتابخانه‌های سبک وب و PWA که اجرای یک سرویس تعاملی با اینترنت ضعیف را واقعی کرده است؛ دوم، فراگیری الگوریتم‌های سنجش تطبیقی در ادبیات علمی که پیاده‌سازی آن‌ها را مستند و قابل دفاع کرده است؛ سوم، تجربه دست‌اول خودم به‌عنوان کاربر: من همین امسال با این مسئله زندگی می‌کنم، هم‌کلاسی‌هایم جامعه آزمودنی من‌اند و دبیرانم می‌توانند صحت تشخیص سیستم را بسنجند. ترکیب «مسئله واقعی + امکان فنی + دسترسی به داده و داور» دقیقاً همان پنجره‌ای است که پروژه را اکنون معنادار می‌کند.

آیا آزمون تطبیقی مبتنی بر Elo همراه با بازخورد مبتنی بر بدفهمی، در یک دوره چهار هفته‌ای، بهبود معنادار و قابل اندازه‌گیری در نمره پس‌آزمون فصل مشتق ایجاد می‌کند؟ سنجه: تفاضل پیشرفت نسبت به گروه کنترل با آزمون ثابت، به همراه اندازه اثر.

بخش سه

۳. اهداف و معیارهای موفقیت

هدف اصلی پروژه، ساختن و علمی‌سازی یک سیستم یادگیری تطبیقی فارسی است؛ اما «هدف» بدون سنجه، شعار است. برای همین هر هدف به یک شاخص کمی وصل شده که در زمان داوری با داده واقعی گزارش می‌شود. اهداف فرعی هم طوری تعریف شده‌اند که حتی اگر اثر آموزشی کوچک‌تر از انتظار از آب درآید، پروژه همچنان یک پژوهش معتبر با یافته قابل انتشار باشد – این نگاه «مسیر بدون شکست» برای یک پروژه دانش‌آموزی حیاتی است.

۳.۱ – اهداف اصلی

- پیاده‌سازی کامل موتور تطبیقی Elo با سیاست انتخاب سؤال در ناحیه هدف ۶۵ تا ۷۵ درصد احتمال موفقیت.
- ساخت گراف بدفهمی فصل مشتق با دست‌کم ده گره مستند و گزینه‌های تشخیصی مپ‌شده به آن.
- اجرای آزمایش کنترل‌شده با چهل آزمودنی و انتشار گزارش نتیجه با اندازه اثر.
- تحویل یک PWA سبک متن‌باز که روی گوشی‌های ضعیف و اینترنت کم‌سرعت کار کند.

۳.۲ – جدول شاخص‌های موفقیت

شاخص	هدف کمی	روش اندازه‌گیری
دقت تشخیص بدفهمی	$\leq 75\%$	تطابق تشخیص سیستم با ارزیابی دبیر روی ۳۰ نمونه تصادفی
اثر یادگیری (تفاضل پیشرفت)	$\leq 20\%$ نسبی	پس‌آزمون منهای پیش‌آزمون؛ مقایسه دو گروه و اندازه اثر
زمان بارگذاری صفحه آزمون	≥ 2 ثانیه	اندازه‌گیری روی شبکه شبیه‌سازی‌شده ۳G

شاخص	هدف کمی	روش اندازه‌گیری
پایداری سیستم	۳۰۰ آزمون بدون خطا	گزارش لاگ خطا در دوره آزمایش
رضایت کاربر	$\leq 4/2$ از ۵	پرسشنامه لیکرت پنج‌سطحی بعد از دوره آزمایش
نرخ بازگشت برای مرور	$\leq 60\%$	نسبت آزمودنی‌هایی که صف مرور هفتگی را کامل کردند

بخش چهار

۴. تحلیل رقابت‌پذیری

پیش از هر چیز باید صادقانه بپذیریم که بازار آموزش کنکور ایران شلوغ است؛ اما «جشنواره علمی» با «بازار رقابتی» دو زمین بازی متفاوت‌اند. داور خوارزمی نمی‌پرسد که آیا این محصول می‌تواند جای ماز را در گوشی‌ها بگیرد؛ می‌پرسد که آیا دانش‌آموز نوآوری فنی، عمق علمی، کیفیت اجرا و روش سنجش درست نشان داده است. با این حال، شناخت دقیق رقبا برای دو چیز ضروری است: فهمیدن اینکه کجاها «تکراری» ساختن یعنی حذف شدن، و پیدا کردن شکاف‌های واقعی که گول‌ها به دلایل ساختاری پُرشان نمی‌کنند.

پلتفرم	مدل اصلی	تطبیق واقعی	تشخیص «چرا غلط»	شفافیت الگوریتم	علم‌آزمایی
ماز	بازی و مسابقه کوپیز با جایزه و لیدربورد	ندارد	ندارد	جعبه‌بسته	ندارد
قلمچی	آزمون آزمایشی و کارنامه رتبه‌محور	برگه ثابت	آماري سطحي	جعبه‌بسته	منتشر نشده
گاج	ناشر؛ پلتفرم دیجیتال مکمل کتاب	ندارد	ندارد	جعبه‌بسته	ندارد
کاگل (خیلی سبز)	آزمون آنلاین و جزوه رایگان	نسبی / سیاه‌جعبه	ندارد	جعبه‌بسته	ندارد
آزمونک	آزمون تطبیقی پژوهش‌محور	Elo شفاف	گراف بدفهمی	متن‌باز	آزمایش کنترل‌شده

شکاف‌های بالا تصادفی نیستند؛ ساختاری‌اند. شرکت‌های تجاری برای اینکه برگه آزمون برای همه یکسان باشد هزینه کمتری می‌پردازند، داده سؤالاتشان دارایی محرمانه است و الگوریتمشان را نمی‌توانند افشا

کنند، و «اثربخشی» را هیچ‌وقت با گروه کنترل اندازه نمی‌گیرند چون نتیجه ممکن است به نفع تبلیغاتشان نباشد. آزمونک دقیقاً از همین سه نقطه وارد می‌شود: تطبیق واقعی به‌جای برگه ثابت، شفافیت به‌جای جعبه سیاه، و عدد علمی به‌جای شعار. به بیان دیگر، ما با این پلتفرم‌ها رقابت فروش نمی‌کنیم؛ روی لایه‌ای کار می‌کنیم که هیچ‌کدام برایش انگیزه ساختاری ندارند و اتفاقاً دقیقاً همان لایه‌ای است که داوران علمی به آن امتیاز می‌دهند.

بخش پنج

۵. تعریف محصول و قابلیت‌ها

محصول نهایی یک وب‌اپلیکیشن تک‌صفحه‌ای سبک است که روی موبایل و دسکتاپ اجرا می‌شود و نصب‌پذیر (PWA) است. تجربه کاربری حول سه صحنه طراحی شده است: «آزمون بده»، «بفهم چرا غلط زدی» و «در زمان درست مرور کن». هر قابلیت به یکی از اهداف بخش سه گره خورده تا از تورم ویژگی‌های بی‌مصرف جلوگیری شود؛ چیزی در نقشه راه نیست مگر اینکه یا یادگیری را عمیق‌تر کند یا داده علمی بیشتری بسازد.

۵.۱ – دامنه قابلیت‌ها

قابلیت	نسخه	شرح
آزمون تطبیقی	MVP	جلسه ۱۰ سؤالی؛ سؤال بعدی بر اساس سطح به‌روزشده دانش‌آموز و سیاست ناحیه هدف انتخاب می‌شود
تشخیص بدفهمی	MVP	هر گزینه غلط به یک گره بدفهمی مپ است؛ پس از دو شاهد مستقل، وضعیت «تثبیت‌شده» و توضیح اختصاصی نمایش داده می‌شود
بانک سؤال فصل مشتق	MVP	۱۵۰ سؤال با برجسب مبحث، سختی اولیه، بدفهمی گزینه‌ها و پاسخ تشریحی
داشبورد تحلیل	نسخه کامل	نمودار راداری مفهوم‌به‌مفهوم، روند توان، فهرست بدفهمی‌های فعال با توضیح
مرور فاصله‌دار	نسخه کامل	صف مرور روزانه بر پایه SM-2؛ مفاهیم درست قبل از سقوط فراموشی برمی‌گردند
پیش‌بینی نمره	نسخه کامل	برآورد نمره آزمون بعدی با رگرسیون وزن‌دار روی ده جلسه آخر + بازه اطمینان
حالت نصب‌پذیر آفلاین	نسخه کامل	Service Worker با کش سشن بعدی؛ اجرای کامل با اینترنت ضعیف

۵.۲ – سناریوی کاربر (جریان جلسه)

- دانش‌آموز «شروع آزمون» را می‌زند؛ سیستم آخرین سطح توان ذخیره‌شده و صف بدفهمی‌های نیمه‌تثبیت‌شده را می‌خواند.
- سؤال اول با سختی نزدیک به سطح فعلی می‌آید؛ پاسخ ضبط و Elo دوطرفه به‌روزرسانی می‌شود؛ اگر گزینه غلط مپ‌دار زده شود، شاهد مربوط به آن بدفهمی ثبت می‌گردد.
- پس از هر پاسخ، بازخورد یک‌خطی نشان داده می‌شود؛ اگر بدفهمی تثبیت شود، توضیح اختصاصی همان بدفهمی به‌همراه یک سؤال اصلاحی هدفمند ارائه می‌گردد.
- در پایان جلسه، خلاصه‌ای سه‌خطی (چه فهمیدی، چه فهمیدنت اشتباه بود، فردا چه مرور کن) به داشبورد اضافه می‌شود و صف SM-2 به‌روزرسانی می‌گردد.

۵.۳ – خارج از دامنه (Non-Goals)

برای حفظ تمرکز، این موارد در نسخه فعلی عمداً ساخته نمی‌شوند: پوشش چنددرسی هم‌زمان، بازی‌سازی و لیدربورد رقابتی (میدان رقبا است و با هدف پژوهشی ما بی‌ربط)، تولید خودکار سؤال با مدل‌های زبانی (به‌دلیل ریسک صحت علمی، فقط در آینده با بازبینی انسانی)، و هر نوع شبکه اجتماعی یا چت. محدودیت آگاهانه دامنه، نشانه بلوغ طراحی است و در دفاع هم به‌عنوان نقطه قوت معرفی می‌شود.

بخش شش

۶. نوآوری‌های شش‌گانه

هر نوآوری در این فهرست، هم یک قابلیت محصول است و هم یک ادعای علمی قابل دفاع؛ به همین دلیل برای هرکدام گفته‌ایم «چرا تکراری نیست» و «داور چه چیزی را می‌بیند». ترتیب، از هسته الگوریتمی به سمت ارزش اجتماعی است.

۱ – موتور آزمون تطبیقی شفاف (Elo)

هر سؤال یک «امتیاز سختی» و هر دانش‌آموز یک «امتیاز توان» دارد که با هر پاسخ دوطرفه به‌روزرسانی می‌شوند؛ سؤال بعدی همیشه در ناحیه‌ای انتخاب می‌شود که احتمال موفقیت بین ۶۵ تا ۷۵ درصد باشد – ناحیه‌ای که طبق مدل جریان، بیشترین یادگیری رخ می‌دهد. تفاوت با کاکل این است که کل ریاضیات سیستم قابل بیان در یک اسلاید است و ما آن را متن‌باز منتشر می‌کنیم؛ تفاوت با آزمون‌های ثابت این است که دو دانش‌آموز مختلف هرگز دو مسیر یکسان نمی‌بینند.

۲- گراف بدفهمی و گزینه‌های تشخیصی

قلب علمی پروژه: گزینه‌های فریبنده هر سؤال نه تصادفی، که «مهندسی‌شده» هستند تا هرکدام یک بدفهمی مفهومی مشخص را به دام بیندازند. انتخاب گزینه توسط دانش‌آموز یک شاهد تشخیصی است و تثبیت هر بدفهمی نیازمند دو شاهد مستقل روی دو سؤال متفاوت است تا خطای تصادفی و شانس حذف شود. ابزارهای فارسی موجود «تعداد غلط» را می‌شمارند؛ آزمونک علت غلط را می‌گوید و برای همان علت، توضیح و تمرین اصلاحی متمایز ارائه می‌دهد.

۳- مرور فاصله‌دار یکپارچه (SM-2)

کیفیت هر پاسخ از سه سیگنال (درستی، خوداظهاری اعتماد، زمان پاسخ) ساخته می‌شود و به الگوریتم SM-2 تغذیه می‌گردد تا فاصله مرور بعدی هر مفهوم را تعیین کند. تفاوت با اپلیکیشن‌های فلش‌کارت این است که مرور اینجا زیرساخت خود آزمون تطبیقی است، نه یک بخش جدا؛ داده توان دانش‌آموز مستقیماً زمان‌بندی مرور را هوشمند می‌کند.

۴- آزمایش علمی با گروه کنترل

هیچ پلتفرم ایرانی‌ای اثر آموزشی روش خود را با طرح پیش‌آزمون/پس‌آزمون و گروه کنترل منتشر نکرده است. ما این کار را با چهل آزمودنی، تصادفی‌سازی و محاسبه اندازه اثر انجام می‌دهیم و نتیجه را - هرچه که باشد - گزارش می‌کنیم. این نوآوری، پروژه را از «یک اپ دیگر» به «یک پژوهش با یافته قابل استناد» تبدیل می‌کند و دقیقاً همان چیزی است که معیار «گام علمی» در داوری می‌سنجد.

۵- پیش‌بینی نمره با بازه اطمینان

یک رگرسیون وزن‌دار ساده روی ده جلسه اخیر، نمره آزمون بعدی را با بازه اطمینان پیش‌بینی می‌کند. عمداً از مدل‌های پیچیده‌تر استفاده نکرده‌ایم تا توضیح‌پذیری حفظ شود: پیش‌بینی قابل دفاع ساده، از تخمین سیاه‌جعبه‌ای غیرقابل توضیح علمی‌تر و برای داور بارزتر است.

کل صفحه آزمون زیر ۲۰۰ کیلوبایت است و با Service Worker روی گوشی‌های ضعیف و اینترنت کم‌سرعت کار می‌کند - چون فراگیری یادگیری نباید قربانی تجهیزات شود. انتشار کد زیر مجوز متن‌باز، هم شفافیت علمی می‌سازد و هم به بقیه دانش‌آموزان امکان می‌دهد برای دروس دیگر توسعه‌اش دهند؛ این «ارزش اجتماعی» در ارائه جشنواره برجسته می‌شود.

بخش هفت

۷. معماری فنی

معماری حول سه اصل طراحی شده است: «سبکی برای کاربر» (صفحات کوچک، بدون وابستگی سنگین)، «سادگی برای تیم یک‌نفره» (کمترین تعداد سرویس متحرک) و «توسعه‌پذیری برای جامعه متن‌باز» (تفکیک کامل الگوریتم از رابط). نتیجه، یک سیستم سه‌لایه کلاسیک است که هر لایه می‌تواند مستقل جابه‌جا یا بازنویسی شود؛ برای مثال اگر بعداً بخواهیم موتور تطبیقی به IRT ارتقا یابد، فقط یک سرویس عوض می‌شود و نه کل پروژه.



۷.۱ - انتخاب فناوری و دلیل آن

- **فرانت‌اند - Next.js (React):** رندر سمت سرور برای بارگذاری سریع روی اینترنت ضعیف، اکوسیستم نمودار سبک، و تجربه ساخت PWA مستند. حجم هدف هر صفحه زیر ۲۰۰ کیلوبایت با بودجه عملکرد سخت‌گیرانه.
- **بک‌اند - FastAPI (Python):** الگوریتم‌ها ماهیت عددی‌اند و پایتون زبان طبیعی آن‌هاست؛ مستندسازی خودکار OpenAPI برای تیم‌های بعدی؛ تست‌پذیری بالا برای اجزای ریاضی.

- **داده – PostgreSQL:** تراکنش‌پذیری برای ثبت صحیح تلاش‌ها، انواع JSONB برای ابرداده سؤال، و شاخص‌گذاری برای انتخاب سؤال در زمان ثابت تقریبی.
- **استقرار – Docker Compose روی یک VPS کوچک:** هزینه‌ای در حد ماهانه چند صد هزار تومان یا رایگان‌تیرهای آموزشی؛ پشتیبان‌گیری روزانه خودکار دیتابیس.

۷.۲ – مدل داده (نمای ساده‌شده)

جدول	فیلدهای کلیدی
users	id، نام نمایشی، کلاس، نقش (دانش‌آموز/دبیر/مدیر)، تاریخ ساخت
questions	id، متن، چهار گزینه، گزینه صحیح، مبحث، سختی اولیه R_q، وضعیت تثبیت سختی، ابرداده JSONB
misconceptions	id، کد (مثل M03)، عنوان، توضیح آموزشی، گره‌های پیش‌نیاز در گراف
question_misconception	question_id، option_id، misconception_id – نقشه گزینه‌های تشخیصی
attempts	id، کاربر، سؤال، گزینه انتخابی، درستی، زمان پاسخ (میلی‌ثانیه)، اعتماد خوداظهاری، R قبل و بعد
ability_state	کاربر، R فعلی، تعداد پاسخ‌ها، K فعلی، تاریخ آخرین به‌روزرسانی
review_schedule	کاربر، مفهوم/سؤال، EF، فاصله فعلی، تاریخ مرور بعدی
misconception_state	کاربر، بدفهمی، تعداد شواهد، وضعیت (مشاهده‌شده/تثبیت‌شده/اصلاح‌شده)

۷.۳ – طراحی API (پایانه‌های اصلی)

POST /api/sessions → شروع جلسه، خواندن وضعیت توان و صف
 GET /api/quiz/next → سؤال بعدی (سیاست ناحیه هدف)
 POST /api/quiz/answer → ثبت پاسخ؛ خروجی: R جدید و وضعیت بدفهمی
 GET /api/analytics/dashboard → رادار مفاهیم، روند توان و بدفهمی‌ها
 GET /api/review/queue → صف مرور روزانه SM-2
 POST /api/review/complete → ثبت کیفیت مرور و به‌روزرسانی فاصله
 همه پاسخ‌ها با کد خطای استاندارد و شناسه درخواست؛ احراز هویت با توکن کوتاه‌عمر.

۸. الگوریتم‌های هسته

این بخش، قلب ریاضی پروژه است و عمداً به قدری شفاف نوشته شده که داور بتواند صحت هر گام را در جلسه دفاع بازبینی کند. چهار قطعه وجود دارد: تخمین توان و سختی با Elo، سیاست انتخاب سؤال، تشخیص بدفهمی با شمارش شواهد، و زمان‌بندی مرور با SM-2؛ به علاوه یک رگرسیون ساده برای پیش‌بینی نمره. پارامترهای دقیق و مقادیر اولیه در پیوست ب آمده است.

۸.۱ – تخمین توان و سختی با Elo

مطابق سنت شطرنج، برخورد «دانش‌آموز با سؤال» یک بازی است: پاسخ صحیح یعنی برد دانش‌آموز. احتمال مورد انتظار موفقیت از تفاوت دو امتیاز به دست می‌آید و پس از هر پاسخ، هر دو امتیاز با نرخ یادگیری K به‌روزرسانی می‌شوند. K دانش‌آموز در شروع بزرگ است (برای حرکت سریع به سطح واقعی) و با تجربه کاهش می‌یابد؛ K سؤال همیشه کوچک است تا سختی سؤالات آهسته و پایدار تثبیت شود.

$$E = 1 / (1 + 10^{((R_q - R_s) / 400)})$$

$$S = 1 \text{ (correct)} \mid 0 \text{ (wrong)}$$

$$R'_s = R_s + K_s * (S - E)$$

$$R'_q = R_q + K_q * ((1-S) - (1-E))$$

R_s : توان دانش‌آموز | R_q : سختی سؤال | E : احتمال موفقیت مورد انتظار | K : نرخ یادگیری

مثال عددی کامل (برای دفاع): دانش‌آموزی با توان ۱۲۰۰ به سؤالی با سختی ۱۳۵۰ پاسخ صحیح می‌دهد. احتمال مورد انتظار برابر است با ۱ بر ۱ به علاوه ده به توان ۱۵۰ تقسیم بر ۴۰۰، یعنی تقریباً ۰/۲۹۶؛ پس این موفقیت «غیرمنتظره» بوده و جایزه بزرگ می‌گیرد: توان جدید برابر ۱۲۰۰ به علاوه ۳۲ ضرب در ۰/۷۰۴، یعنی حدود ۱۲۲۲/۵. سؤال هم چون از دانش‌آموز «بُخت»، سختی‌اش ۵/۶ واحد کم می‌شود و به ۱۳۴۴/۴ می‌رسد. همین دو خط، کل «هوش» سیستم است و قابل توضیح برای هر مخاطبی.

۸.۲ – سیاست انتخاب سؤال بعدی

انتخاب سؤال یک بهینه‌سازی محدودیت‌دار است: از میان سؤالات «کandid»، باید سؤالی را برداریم که هم در ناحیه چالش مؤثر باشد و هم بیشترین ارزش آموزشی را داشته باشد. امتیاز کاندیدها با ترکیب سه وزن محاسبه می‌شود: بزرگی ضعف در مبحث (بر پایه بدفهمی‌های فعال)، اهمیت مبحث در آزمون نهایی، و فاصله زمانی از آخرین برخورد. سپس در میان ده کاندید برتر، سؤالی انتخاب می‌شود که احتمال موفقیتش به میانه ناحیه هدف نزدیک‌ترین باشد.

سؤال خیلی آسان، یادگیری نمی‌سازد و فقط اعتماد به نفس کاذب می‌دهد؛ سؤال خیلی سخت، ناکامی می‌سازد و رهاشدگی می‌آورد. ناحیه میانی کمی بالاتر از سطح فعلی، جایی است که طبق ادبیات «چالش بهینه» و مدل جریان، تعادل تلاش و موفقیت برقرار است. محدوده را در آزمایش علمی حساسیت‌سنجی می‌کنیم تا ادعا تجربه‌محور شود.

۸.۳ – تشخیص بدفهمی با شمارش شواهد

هر گزینه فریبنده به یک گره در گراف بدفهمی گره خورده است. وقتی دانش‌آموز گزینه‌ای را انتخاب می‌کند که به بدفهمی M وصل است، یک «شاهد» برای M ثبت می‌شود. وضعیت‌ها سه‌تایی‌اند: **مشاهده‌شده** (یک شاهد)، **تثبیت‌شده** (دو شاهد مستقل روی دو سؤال متفاوت در دو جلسه) و **اصلاح‌شده** (پس از پاسخ صحیح به سؤال اصلاحی هدفمند همان بدفهمی، شاهد منفی ثبت می‌شود). قاعده «دو شاهد» آگاهانه سخت‌گیرانه است: هزینه اشتباه برچسب‌زدن یک نوجوان به «نمی‌فهمی»، از هزینه یک جلسه تشخیص دیرتر بیشتر است. سیستم همچنین برای هر بدفهمی تثبیت‌شده، گره‌های پیش‌نیاز آن را از گراف بررسی می‌کند تا توضیح، از ریشه شروع شود.

۸.۴ – زمان‌بندی مرور با SM-2

$q = f(\text{correct}, \text{confidence}, \text{latency}), \quad q \text{ in } 0..5$
 $EF' = \max(1.3, EF + (0.1 - (5-q) * (0.08 + (5-q) * 0.02)))$
 $I(1) = 1 \text{ day}; \quad I(2) = 6 \text{ days}; \quad I(n) = \text{ceil}(I(n-1) * EF)$

q: کیفیت پاسخ | EF: سادگی نسبی هر آیتم | I(n): فاصله مرور بعدی (روز)

تابع کیفیت، سه سیگنال را ترکیب می‌کند: درستی وزن اصلی را دارد، اعتماد خوداظهاری (مطمئن بودم / حدس می‌زدم) کیفیت را جابه‌جا می‌کند و تأخیر غیرعادی در پاسخ، نیم واحد از q کم می‌کند. مثال: مفهومی که سه بار پیوسته با اطمینان بالا درست پاسخ داده شده، EF حدود ۲/۵ می‌گیرد و فاصله مرورش از یک روز به شش روز و سپس به حدود پانزده روز می‌رسد؛ همان مفهوم با یک حدس درست، EF پایین‌تر و فاصله کوتاه‌تر خواهد داشت.

۸.۵ – پیش‌بینی نمره آزمون بعدی

برای هر دانش‌آموز با دست‌کم هشت جلسه ثبت‌شده، یک رگرسیون خطی وزن‌دار روی نمرات جلسات اخیر برازش می‌شود؛ وزن جلسات جدیدتر نمایی بزرگ‌تر است ($\lambda = 0.85$) تا روند اخیر بر میانگین کل غلبه کند. خروجی همیشه با بازه اطمینان (یک انحراف معیار باقیمانده) نمایش داده می‌شود تا دانش‌آموز «عدد قطعی» نبیند و درک سالم از عدم قطعیت شکل بگیرد. سادگی عمده این مدل، خودش

۹. بانک سؤال و مدل داده محتوایی

بانک سؤال، دارایی حقیقی این پروژه است و کیفیت تشخیص، هرگز از کیفیت محتوا بیشتر نمی‌شود. هر سؤال یک رکورد ساختارمند است؛ نه فقط متن و گزینه، بلکه نقشه کامل «هر گزینه به کدام بدفهمی اشاره می‌کند». برای MVP روی فصل مشتق حسابان یازدهم، ۱۵۰ سؤال در سه رده سختی و ده گره بدفهمی هدف‌گذاری شده است؛ توزیع به‌گونه‌ای است که هر بدفهمی دست‌کم در شش سؤال شانس مشاهده داشته باشد.

۹.۱ – تاکسونومی بدفهمی‌های فصل مشتق (گره‌های گراف)

کد	بدفهمی	نشانه رفتاری در پاسخ‌ها
M01	مشتق را «تفاضل» می‌فهمد نه نرخ لحظه‌ای	گزینه‌هایی برمی‌گزیند که $f(b) - f(a)$ را معادل مشتق می‌گیرند
M02	مشتق را مقدار تابع می‌پندارد	$f(a)$ را با $f'(a)$ اشتباه می‌گیرد
M03	مماس را با واصل جایگزین می‌کند	شیب خط دونقطه را برای نقطه‌ای گزارش می‌کند
M04	$f'(x) = 0$ را کافی برای اکسترمم می‌داند	بررسی علامت مشتق در اطراف نقطه را حذف می‌کند
M05	مشتق حاصل ضرب = ضرب مشتق‌ها	$(fg)'$ را $f'g$ می‌نویسد
M06	قاعده زنجیره‌ای: ضرب به‌جای ترکیب	$f'(g(x))$ را بدون $g'(x)$ می‌گیرد
M07	صعودی بودن نقطه‌ای و بازه‌ای را یکی می‌گیرد	از یک مثبت بودن مشتق در یک نقطه، صعودی بودن کل بازه را نتیجه می‌کند
M08	مشتق‌پذیری را با پیوستگی یکی می‌گیرد	برای توابع شکسته یا گوشه‌دار (مثل قدرمطلق در صفر) مشتق‌پذیری می‌پذیرد
M09	خطای توان منفی و ریشه در قاعده توان	مشتق x^{-n} یا جذر را با نتوان درست حساب می‌کند
M10	مشتق تابع ثابت را صفر نمی‌داند	در ساده‌سازی‌ها جمله ثابت را حذف نمی‌کند

- **نگارش اصل:** سؤالات بر پایه اهداف یادگیری کتاب درسی نوشته می‌شوند، نه کپی از منابع تجاری؛ هر سؤال با نام نویسنده و مجوز CC BY-NC ثبت می‌شود تا لایسنس متن‌باز پروژه پاک بماند.
- **بازبینی دو مرحله‌ای:** مرحله یک، بازبینی علمی توسط دبیر ریاضی (صحت پاسخ و مب بدفهمی‌ها)؛ مرحله دو، آزمایش با پنج تا هشت دانش‌آموز خارج از گروه اصلی برای سنجش خوانایی و سختی اولیه.
- **تثبیت سختی:** سختی اولیه هر سؤال دستی تنظیم می‌شود اما با حدود بیست پاسخ واقعی، رأی جامعه کاربران جایگزین تقریب انسانی می‌شود؛ سؤالات با پراکندگی غیرعادی در بازبینی قرار می‌گیرند.
- **سلامت داده آزمایش:** سؤالات تازه‌ساخت به هیچ‌وجه قبل از پس‌آزمون در اختیار آزمودنی‌ها قرار نمی‌گیرند تا اثر «دیده‌بودن» صفر باشد.

بخش ده

۱۰. طراحی آزمایش علمی

آزمایش، لنگرگاه اعتبار این پروژه است. طرح انتخاب‌شده «پیش‌آزمون/پس‌آزمون با گروه کنترل» است؛ ساده‌ترین طرحی که هم علت‌مندی را پشتیبانی می‌کند و هم با منابع یک دانش‌آموز اجراپذیر است. چهل داوطلب داوطلب از دو کلاس موازی جذب و پس از پیش‌آزمون مشترک، به‌صورت تصادفی بلوکه‌شده بر اساس نمره پیش‌آزمون به دو گروه بیست‌نفره تقسیم می‌شوند تا توزیع توان اولیه در دو گروه هم‌تراز باشد.

۱۰.۱ – پروتکل چهار هفته‌ای

هفته	گروه آزمایش	گروه کنترل
۰	پیش‌آزمون استاندارد ۲۵ سؤالی از کل فصل مشتق + پرسشنامه اطلاعات پایه (۱۰ دقیقه)	
۱ تا ۴	چهار جلسه در هفته با آزمونک: آزمون تطبیقی ۱۰ سؤالی + صف مرور SM-2 (هر جلسه حدود ۲۰ دقیقه)	چهار جلسه در هفته با آزمون ثابت هم‌حجم از همان بانک سؤال، بدون تطبیق و بدون تشخیص بدفهمی
۴	پس‌آزمون موازی پیش‌آزمون (سؤالات متفاوت با همان جدول مشخصات) + پرسشنامه رضایت لیکرت	

متغیر وابسته اصلی «تفاضل پیشرفت» است: نمره پس‌آزمون منهای نمره پیش‌آزمون هر فرد. مقایسه میانگین دو گروه با آزمون تی مستقل انجام می‌شود و به‌جای اتکای صرف به مقدار p ، اندازه اثر کوهن (d) گزارش می‌شود تا بزرگی عملی یافته مشخص باشد. سنجه‌های فرعی: نرخ برطرف شدن بدفهمی‌ها در گروه آزمایش (مقایسه وضعیت گره‌ها قبل و بعد)، زمان تا تسلط هر مبحث، و نرخ تکمیل صف مرور. تحلیل با اسکریپت پایتون متن‌باز انجام و داده‌های ناشناس‌شده در مخزن پروژه منتشر می‌شود تا هر کسی بتواند محاسبات را بازتولید کند.

صداقت علمی – محدودیت‌هایی که خودمان اعلام می‌کنیم

حجم نمونه کوچک است و نتایج قابل تعمیم آماری به کل کشور نیست؛ دوره چهار هفته‌ای است و اثر بلندمدت سنجیده نمی‌شود؛ و اثر «توجه ویژه» بین گروه‌ها کاملاً صفر نیست. این محدودیت‌ها در گزارش نوشته می‌شوند، نه پنهان – و همین صداقت، تفاوت یک پژوهش دانش‌آموزی جدی با یک دموع بازاریابی است.

۱۰.۳ – ملاحظات اخلاقی

مشارکت داوطلبانه و با رضایت‌نامه کتبی والدین برای افراد زیر هجده سال است؛ داده‌ها با شناسه کدشده و بدون نام ذخیره می‌شوند؛ گروه کنترل پس از پایان آزمایش به کامل‌ترین نسخه سیستم دسترسی می‌یابد تا هیچ‌کس از منفعت آموزشی محروم نماند؛ و هر زمان آزمودنی بخواهد، بدون هیچ پیامدی از مطالعه خارج می‌شود.

بخش یازده

۱۱. نقشه راه اجرایی

نقشه راه بر پایه هفته‌های تقویمی از مهر تنظیم شده است؛ چون تاریخ دقیق فراخوان و داوری هر سال کمی جابه‌جا می‌شود، فازها به‌جای تاریخ ثابت، به مایلستون‌های قابل اثبات وصل‌اند و اگر فراخوان زودتر یا دیرتر اعلام شود، فقط مرز فازها جابه‌جا می‌شود نه ساختار کار. قاعده مدیریت ریسک زمانی این است: در هر لحظه، «آخرین نسخه پایدار» همیشه آماده داوری است.

فاز ۰ طراحی و اسکلت

هفته ۱ تا ۲

نهایی‌سازی معماری، راه‌اندازی مخزن متن‌باز و خط CI، ساخت جداول دیتابیس و قالب رکورد سؤال، طراحی رابط‌های کلیدی به‌صورت صفحات خام کارا.

مایلستون: ورود و ثبت سؤال در محیط واقعی کار می‌کند

فاز ۱ MVP الگوریتم

هفته ۳ تا ۵

پیاده‌سازی کامل Elo و سیاست ناحیه هدف، ساخت ۵۰ سؤال نخست فصل مشتق با مپ بدفهمی، جریان کامل «شروع تا پایان» یک جلسه آزمون.

مایلستون: اولین جلسه تطبیقی کامل و بی‌خطا

فاز ۲ هوش و محتوا

هفته ۶ تا ۸

سرویس تشخیص بدفهمی با قاعده دو شاهد، مرور فاصله‌دار SM-2، داشبورد تحلیل، رسیدن بانک سؤال به ۱۵۰، تست خودکار الگوریتم‌ها با سناریوهای شبیه‌سازی‌شده.

مایلستون: نسخه پایدار آماده آزمایش میدانی

فاز ۳ آزمایش علمی

هفته ۹ تا ۱۲

جذب چهل داوطلب و رضایت‌نامه‌ها، اجرای چهار هفته‌ای پروتکل، مانیتورینگ روزانه پایداری، تحلیل داده و نگارش گزارش نتایج با اندازه اثر.

مایلستون: گزارش علمی با اعداد واقعی

فاز ۴ بسته‌بندی و دفاع

هفته ۱۳ تا ۱۴

پولیش رابط، ضبط ویدیوی دمو سهدقیقه‌ای، آماده‌سازی پوستر و سند خلاصه، تمرین ارائه و شبیه‌سازی پرسش و پاسخ بر اساس بخش سیزده همین سند.

مایلستون: بسته کامل جشنواره آماده ثبت

بخش دوازده

۱۲. ریسک‌ها و ملاحظات

پروژه بدون شناسایی ریسک، فقط امید است. جدول زیر شش ریسک اصلی را با ارزیابی احتمال و شدت اثر و راهکار مشخص فهرست می‌کند؛ قاعده مدیریت این است که برای هر ریسک «بالا/بالا» یک طرح

جایگزین از قبل نوشته شده باشد، نه اینکه در لحظه بحران تصمیم‌گیری شود. مرور این جدول هر دو هفته یک‌بار در جلسه با دبیر راهنما انجام می‌شود.

ریسک	احتمال	اثر	راهکار کاهش
کندی تولید محتوای سؤال باکیفیت	بالا	بالا	شروع تولید از فاز ۰ با سهمیه روزانه؛ قالب استاندارد سؤال؛ مشارکت داوطلبانه دو دانش‌آموز برتر با نام در متن‌باز؛ حداقل قابل قبول MVP؛ هشتاد سؤال
خطای الگوریتم در تشخیص (مثبت/منفی کاذب)	متوسط	بالا	قاعده دو شاهد مستقل؛ لاگ کامل برای بازبینی هفتگی دبیر؛ دکمه «اعتراض به تشخیص» در رابط؛ سنج دقت در KPI
ریزش آزمودنی‌ها در حین آزمایش چهار هفته‌ای	متوسط	متوسط	جذب ۴۸ نفر برای رسیدن به ۴۰؛ جلسات کوتاه ۲۰ دقیقه‌ای؛ یادآور پیامکی؛ تحلیل با اصل «قصد درمان» برای افت‌ها
خستگی و افت انگیزه خود توسعه‌دهنده	متوسط	بالا	مایلستون‌های دو هفته‌ای با جشن کوچک؛ دفتر پیشرفت؛ نسخه پایدار همیشه آماده تا شکست فاز، پروژه را نسوزاند
ناپایداری سرویس میزبان در روز دآوری	کم	بالا	دموی آفلاین روی لپ‌تاپ با دیتابیس محلی و نسخه Docker؛ ویدیوی ضبط‌شده به‌عنوان پشتیبان؛ دو مسیر اینترنت مستقل
ابهام لایسنس محتوای سؤالات	کم	متوسط	فقط نگارش اصل؛ ثبت منشأ هر سؤال؛ مجوز CC BY-NC؛ بازبینی نهایی با دبیر راهنما قبل از انتشار عمومی

بخش سیزده

۱۳. آمادگی دفاع – پرسش‌های احتمالی داوران

این بخش تمرین ارائه است: ده پرسشی که با احتمال بالا در دآوری مطرح می‌شود، همراه با پاسخ کوتاه آماده. هدف حفظ‌کردن متن نیست؛ درک این است که هر پاسخ از کدام بخش سند می‌آید تا در لحظه، با اطمینان و ارجاع، دفاع کنیم.

۱. فرق این پروژه با ماز و قلمچی چیست؟

سه لایه تمایز مستند داریم: تطبیق واقعی و شفاف بر پایه Elo در حالی که آزمون‌های موجود برگه ثابت یا جعبه‌سیاه می‌دهند؛ تشخیص «چرا غلط زدی» با گزینه‌های تشخیصی و گراف بدفهمی که در هیچ ابزار فارسی وجود ندارد؛ و انتشار نتایج آزمایش کنترل‌شده با گروه کنترل که هیچ پلتفرم تجاری آن را منتشر نمی‌کند. به بیان فنی، ما در لایه «سنجش تطبیقی پژوهش‌محور» کار می‌کنیم که در آن رقابت مستقیم نداریم.

۲ چرا Elo و نه مدل‌های پیشرفته‌تر مثل IRT سه‌پارامتری؟

انتخاب الگوریتم تابع حجم داده است، نه مد روز. IRT برای برآورد دقیق پارامترها به هزاران پاسخ نیاز دارد؛ داده ما در مقیاس یک مدرسه است و Elo با ده‌ها پاسخ هم کار می‌کند، کم‌حساس به داده پراکنده و کاملاً توضیح‌پذیر است. مسیر ارتقا در سند معماری پیش‌بینی شده: با انباشت داده، سرویس الگوریتم بدون تغییر بقیه سیستم به IRT ارتقا می‌یابد.

۳ با چهل آزمودنی، اعتبار علمی نتیجه چه قدر است؟

قدرت آماری محدود را خودمان در سند اعلام کرده‌ایم و ادعا را محافظه‌کارانه می‌کنیم: نتیجه «تعمیم‌پذیر ملی» نیست، اما با طرح پیش‌آزمون/پس‌آزمون، تصادفی‌سازی بلوکه‌شده و گزارش اندازه اثر کوهن، یافته‌ای معتبر در مقیاس مورد مطالعه است. هدف یک پژوهش دانش‌آموزی، روش درست و شفافیت است که هر دو تضمین شده‌اند؛ تکرار در مقیاس بزرگ‌تر، ادامه طبیعی این کار است.

۴ چقدر از این کار واقعاً ساخته خود شماست؟

در توسعه از ابزارهای هوشمند کمک گرفته‌ایم – همان‌طور که مهندسان امروز همه‌جا می‌کنند – اما تصمیم‌های اصلی، کار اصلی پژوهش است: طراحی الگوریتم و انتخاب پارامترها، ساخت تاکسونومی بدفهمی با دبیرم، طراحی آزمایش و تحلیل داده. من ریاضیات Elo و SM-2 را با مثال عددی توضیح می‌دهم، هر خط کد حساس را می‌شناسم و آماده‌ام هر بخش را روی تخته بازسازی کنم؛ ابزار سرعت بخشید، نه جایگزین فهم.

۵ سؤالات را از کجا می‌آورید و حق نشر چه می‌شود؟

همه سؤالات اصل و بر پایه اهداف یادگیری کتاب درسی نوشته می‌شوند، با بازبینی علمی دبیر ریاضی و ثبت منشأ هر سؤال در مخزن. مجوز محتوا CC BY-NC است و هیچ استفاده از بانک‌های تجاری نداریم؛ برای ما این هم مسئله اخلاقی است و هم الزام متن‌باز بودن پروژه.

۶ چرا وب، نه اپلیکیشن موبایل بومی؟

سه دلیل مهندسی: PWA روی هر گوشی با هر سیستم‌عاملی نصب می‌شود بدون بابازار و بی‌نیاز از دو نسخه جدا؛ نگهداری یک کدبیس برای تیم یک‌نفره واقع‌بینانه است؛ و بهینه‌سازی سبکی ما (صفحه زیر ۲۰۰ کیلوبایت و کش آفلاین) دقیقاً برای مخاطب کم‌امکانات طراحی شده که هدف اجتماعی پروژه است.

۷ اگر سیستم یک دانش‌آموز را اشتباه تشخیص بدهد چه؟

سه سپر داریم: قاعده دو شاهد مستقل که برچسب‌زدن تکرر خدای را حذف می‌کند؛ بازبینی هفتگی لاگ‌ها توسط دبیر که هر تشخیص تثبیت‌شده را تأیید یا رد می‌کند؛ و دکمه اعتراض در رابط کاربری که تشخیص را به صف بازبینی انسانی می‌فرستد. دقت تشخیص یکی از شاخص‌های کمی سند است و با داده واقعی گزارش می‌شود.

۸ مقیاس‌پذیری سیستم چطور است؟

سرویس‌ها بدون وضعیت (stateless) هستند و انتخاب سؤال با شاخص‌گذاری مناسب در زمان تقریباً ثابت اجرا می‌شود؛ همین معماری روی یک سرور کوچک به راحتی چند هزار کاربر هم‌زمان را پشتیبانی می‌کند که برای فاز پژوهش و سال‌های نخست انتشار کافی است. گلوگاه واقعی، تولید محتوای باکیفیت است نه زیرساخت – و آن را در ریسک‌ها مدیریت کرده‌ایم.

۹ امنیت و حریم خصوصی نوجوان‌ها چطور رعایت می‌شود؟

اصول حداقل‌سازی داده را اجرا می‌کنیم: بدون نام واقعی در دیتابیس آزمایش، بدون هیچ داده حساس، انتقال فقط با HTTPS و توکن کوتاه‌عمر، و رضایت‌نامه کتبی والدین برای همه آزمودنی‌ها. داده‌های منتشرشده در مخزن علمی، کاملاً ناشناس‌شده و فقط با شناسه کد هستند.

۱۰ آینده این پروژه چیست؟

سه گام: تکمیل دروس پایه یازدهم و دوازدهم با مشارکت دبیران در چارچوب متن‌باز؛ ارتقای الگوریتم به IRT با انباشت داده؛ و به عنوان ایده پژوهشی بعدی، استفاده از مدل‌های زبانی برای تولید خودکار «توضیح فارسی» هر بدفهمی با بازبینی انسانی – نه تولید سؤال. نقشه بلندمدت، تبدیل آزمونک به زیرساخت سنجش تطبیقی باز برای مدرسه‌هاست.

بخش چهارده – پیوست‌ها

۱۴. پیوست‌ها

پیوست الف – نمونه کامل یک سؤال تشخیصی

مثال زیر ساختار استاندارد سؤالات آزمونک را نشان می‌دهد: صورت مسئله، چهار گزینه، و نقشه هر گزینه به گره بدفهمی. دقت کنید که گزینه‌های فریبنده «غلط‌های بی‌ربط» نیستند؛ هرکدام پاسخ منطقی یک فهم غلط مشخص است – همین ویژگی، سیگنال تشخیصی می‌سازد.

سؤال نمونه – مفهوم مشتق در نقطه

مشتق تابع f در نقطه $x = 2$ برابر ۳ است. این گزاره دقیقاً به چه معناست؟

M01 تفاضل مقادیر تابع فاصله دو واحدی برابر ۳ است؛ یعنی $f(4) - f(2) = 3$.

پاسخ صحیح آهنگ تغییر لحظه‌ای f در نقطه $x = 2$ برابر ۳ است؛ یعنی شیب خط مماس در آن نقطه.

M07 تابع از نقطه $x = 2$ به بعد همیشه صعودی است و شیبش دائماً ۳ می‌ماند.

M02 مقدار تابع در آن نقطه برابر ۳ است؛ یعنی $f(2) = 3$.

اقدام پس از پاسخ: انتخاب گزینه دوم، نخستین شاهد M01 را ثبت می‌کند و بازخورد یک‌خطی «تفاضل، میانگین تغییر را می‌گوید؛ مشتق، تغییر در یک لحظه» نمایش داده می‌شود. تثبیت M01 در جلسه بعد، سؤال اصلاحی هدفمند «نرخ متوسط در مقابل نرخ لحظه‌ای» را به صف می‌فرستد.

پیوست ب – جدول پارامترهای الگوریتم‌ها

پارامتر	مقدار اولیه	توضیح
K دانش‌آموز (شروع)	۳۲	پس از ۵۰ پاسخ به ۲۴ و پس از ۱۵۰ پاسخ به ۱۶ کاهش می‌یابد
K سؤال	۸	پس از ۴۰ پاسخ به ۴ کاهش می‌یابد؛ تثبیت آهسته سختی
ناحیه هدف انتخاب	۰/۶۵ تا ۰/۷۵	احتمال موفقیت مورد انتظار سؤال بعدی؛ حساسیت‌سنجی در آزمایش
قاعده تثبیت بدفهمی	۲ شاهد	روی دو سؤال متفاوت در دو جلسه؛ اصلاح با سؤال اصلاحی هدفمند
کف EF در SM-2	۱/۳	سادگی نسبی هر آیتم هرگز زیر این کف نمی‌رود
وزن افت روند پیش‌بینی	$\lambda = 0/85$	وزن نمایی جلسات اخیر در رگرسیون پیش‌بینی نمره
حداقل جلسه برای پیش‌بینی	۸	پیش از آن، پیش‌بینی نمایش داده نمی‌شود تا گمراه‌کننده نباشد
بودجه حجم صفحه آزمون	۲۰۰ کیلوبایت	شامل فونت فرعی؛ اندازه‌گیری روی شبکه شبیه‌سازی‌شده ۳G

- **آزمون تطبیقی:** آزمونی که سؤال بعدی‌اش بر اساس عملکرد لحظه‌ای آزمودنی انتخاب می‌شود.
- **بدفهمی (Misconception):** درک غلط و پایدار از یک مفهوم که الگوی خطای قابل پیش‌بینی تولید می‌کند.
- **گزینه تشخیصی:** گزینه فریبنده‌ای که به یک بدفهمی مشخص گره خورده و انتخاب آن، شاهد آن بدفهمی است.
- **Elo:** الگوریتم رتبه‌دهی دوطرفه مبتنی بر احتمال برد مورد انتظار؛ اینجا بین دانش‌آموز و سؤال.
- **SM-2:** الگوریتم تکرار فاصله‌دار که فاصله مرور بعدی را بر اساس کیفیت یادآوری تنظیم می‌کند.
- **گروه کنترل:** گروهی که مداخله را نمی‌گیرد و برای مقایسه علت‌مند استفاده می‌شود.
- **اندازه اثر (Cohen's d):** سنج استاندارد بزرگی تفاوت دو گروه، مستقل از حجم نمونه.
- **PWA:** وب‌اپلیکیشن پیشرفته؛ قابل نصب با پشتیبانی آفلاین از طریق Service Worker.

یادگیری وقتی عمیق می‌شود که سیستم بپرسد: «چرا؟»

آزمونک – دستیار هوشمند آزمون تطبیقی با تشخیص بدفهمی‌های مفهومی

پدیدآور: پویا

راهنمای آموزشی:

جشنواره نوجوان خوارزمی – رشته رایانه، نرم‌افزار و هوش مصنوعی

آزمونک

دستیار هوشمند آزمون تطبیقی با **تشخیص بدفهمی‌های مفهومی** - هر دانش‌آموز، یک مسیر یادگیری مخصوص به خودش



نسخه ارائه

مهر ۱۴۰۵

مدرسه

.....

دبیر راهنما

.....

پدیدآور

پویا

مسئله، بعد راه حل چرا آزمونک؟

ابزارهای موجود «چند درصد غلط زدی» را می‌گویند؛ هیچ‌کدام نمی‌گویند «چرا غلط زدی» – و هیچ‌کدام اثر روششان را با آزمایش علمی نشان نمی‌دهند.

سه گلوگاه آزمون‌های امروزی

پاسخ آزمونک

آزمون یکسان برای همه

برگه ثابت: نه هم‌سطح ضعیف‌ها، نه هم‌سطح قوی‌ها – هیچ‌کس در ناحیه یادگیری بهینه نیست

موتور تطبیقی Elo

سؤال بعدی همیشه در ناحیه ۶۵ تا ۷۵ درصد احتمال موفقیت – چالش بهینه برای هر فرد

بازخورد آماری سطحی

«در مشتق ۴۰٪» – اما عجله است یا بدفهمی مفهومی؟ درمان این دو یکی نیست

گراف بدفهمی

گزینه‌های فریبنده مهندسی‌شده‌اند: انتخاب هرکدام، یک بدفهمی مشخص را افشا می‌کند

نادیده گرفتن فراموشی

هیچ مکانیزمی مفهوم را دقیقاً قبل از سقوط یادگیری به یادآوری برنمی‌گرداند

مرور فاصله‌دار SM-2

صف مرور روزانه بر پایه منحنی فراموشی؛ یکپارچه با خودِ آزمون

شش نوآوری فنی

هرکدام یک ادعای قابل دفاع

۱

موتور تطبیقی شفاف

توان دانش‌آموز و سختی سؤال با الگوریتم Elo دوطرفه به‌روزرسانی می‌شود؛ کل ریاضیات سیستم در یک اسلاید قابل توضیح و کاملاً متن‌باز است.

۲

تشخیص «چرا غلط زدی»

هر گزینه فریبنده به یک بدفهمی مفهومی گره خورده؛ تثبیت تشخیص نیازمند دو شاهد مستقل — نه یک حدس آماری.

۳

مرور فاصله‌دار یکپارچه

کیفیت پاسخ از سه سیگنال ساخته و به SM-2 تغذیه می‌شود؛ مرور، زیرساخت خود آزمون است نه یک بخش جدا.

۴

آزمایش علمی با گروه کنترل

چهل آزمودنی، پیش‌آزمون/پس‌آزمون و گزارش اندازه اثر کوهن — چیزی که هیچ پلتفرم تجاری منتشر نمی‌کند.

۵

پیش‌بینی با بازه اطمینان

رگرسیون وزن‌دار روی جلسات اخیر؛ سادگی عمدی به‌جای جعبه سیاه — توضیح‌پذیری یعنی اعتماد.

۶

سبک، آفلاین، متن‌باز

صفحه آزمون زیر ۲۰۰ کیلوبایت و نصب‌پذیر (PWA)؛ برای بچه‌های شهرستان با گوشی ضعیف و نت کم.

معماری و الگوریتم‌ها

سه لایه، چهار قطعه هوشمند

معماری سه لایه

لایه نمایش

۲۰۰KB صفحه آزمون زیر Next.js + PWA

▼ HTTPS / JSON ▼

لایه سرویس (FastAPI)

موتور تطبیقی · بدفهمی · مرور · تحلیل

▼ SQL / Cache ▼

لایه داده (PostgreSQL)

کاربران، سؤالات، تلاش‌ها، برنامه مرور

چرا این استک؟ الگوریتم‌ها عددی‌اند و پایتون زبان طبیعی‌شان است؛ PWA روی هر گوشی نصب می‌شود بدون نیاز به اپ استور؛ و تفکیک لایه‌ها ارتقای آینده الگوریتم (به IRT) را بدون بازنویسی ممکن می‌کند.

حلقه هوشمند

$$E = 1 / (1 + 10^{((R_q - R_s)/400)})$$
$$R' = R + K * (S - E)$$

احتمال موفقیت مورد انتظار و به‌روزرسانی دوطرفه توان/سختی

Select next: argmin |E - 0.70|
s.t. topic weight, not seen in 20

سیاست انتخاب: ناحیه هدف ۰/۶۵ تا ۰/۷۵ + ارزش آموزشی مبحث

$$EF' = EF + (0.1 - (5-q)*(0.08+(5-q)*0.02))$$
$$I(n) = \text{ceil}(I(n-1) * EF)$$

زمان‌بندی مرور SM-2 بر اساس کیفیت پاسخ q

رقبا و تمایز

ما کجا می‌جنگیم؟

پلتفرم	مدل اصلی	تطبیق واقعی	تشخیص «چرا غلط»	شفافیت	علم‌آزمایی
ماز	بازی و مسابقه کوپیز	ندارد	ندارد	بسته	ندارد
قلمچی	آزمون آزمایشی رتبه‌محور	برگه ثابت	آماري سطحي	بسته	منتشر نشده
گاج	ناشر؛ مکمل دیجیتال کتاب	ندارد	ندارد	بسته	ندارد
کاگل	آزمون آنلاین رایگان	نسبی	ندارد	بسته	ندارد
آزمونک	سنجش تطبیقی پژوهش‌محور	Elo شفاف	گراف بدفهمی	متن‌باز	کنترل‌شده

جایگاه ما: ضعف رقبا ساختاری است — برگه ثابت ارزان‌تر است، الگوریتم محرمانه است و اثربخشی را کسی اندازه نمی‌گیرد. ما دقیقاً روی همان لایه‌ای کار می‌کنیم که داوران علمی امتیاز می‌دهند.

نقشه راه – ۱۴ هفته

از امروز تا بسته داوری

فاز ۰ هفته ۱-۲

طراحی و اسکلت

معماری، مخزن متن‌باز، دیتابیس، قالب
سؤال

فاز ۱ هفته ۳-۵

MVP الگوریتم

Elo کامل + ۵۰ سؤال فصل مشتق +
جریان جلسه

فاز ۲ هفته ۶-۸

هوش و محتوا

بدفهمی، SM-2، داشبورد – ۱۵۰ سؤال

فاز ۳ هفته ۹-۱۲

آزمایش علمی

۴۰ آزمودنی، تحلیل، گزارش با اندازه اثر

فاز ۴ هفته ۱۳-۱۴

بسته داوری

دمو، پوستر، تمرین ارائه و پرسش‌وپاسخ

۶

نوآوری مستند

۱۵۰

سؤال هدف MVP

۴۰

آزمودنی واقعی

≥ ۷۵%

هدف دقت تشخیص

متن‌باز

کد و داده تحلیل

یادگیری وقتی عمیق می‌شود که سیستم بپرسد: «چرا؟»